Document de test pour un système RAG

Organisation fictive : NovaTech Solutions
Ce document contient volontairement des informations précises, réparties dans plusieurs sections, afin de tester un pipeline RAG : chargement, découpage, embeddings, recherche sémantique, génération de réponses et citation des sources.

1. Présentation générale

NovaTech Solutions est une entreprise fictive créée en 2018 à Casablanca. Elle développe des solutions logicielles pour les entreprises dans les domaines de l'intelligence artificielle, de l'analyse de données et de l'automatisation. En septembre 2026, l'entreprise compte 146 employés répartis entre Casablanca, Rabat et un petit bureau de recherche à Tanger.

La direction générale est assurée par Salma El Idrissi. Le directeur technique est Youssef Amrani, et la responsable du pôle Data & AI est Nadia Benjelloun. Le département Data & AI comprend 38 personnes, dont 17 data scientists, 9 data engineers, 7 machine learning engineers et 5 analystes BI.

La mission de NovaTech Solutions est de rendre les outils d'analyse avancée accessibles aux équipes métier qui ne disposent pas nécessairement de compétences en programmation.

2. Produit principal : InsightFlow

InsightFlow est la plateforme principale de NovaTech. Elle permet d'importer des fichiers CSV, XLSX et JSON, de générer automatiquement des analyses exploratoires et de créer des tableaux de bord interactifs. La version 3.2, publiée le 14 juillet 2026, a ajouté un assistant conversationnel capable d'interroger les jeux de données en langage naturel.

L'architecture d'InsightFlow 3.2 repose sur Django pour le backend, PostgreSQL pour les données transactionnelles, Redis pour le cache et Plotly pour les visualisations. Les traitements asynchrones sont exécutés avec Celery. Pour les fonctions d'IA générative, la plateforme utilise une couche d'orchestration indépendante du fournisseur de modèle.

Pour des raisons de confidentialité, les données brutes des clients ne sont pas envoyées directement au modèle de langage. Le système privilégie l'envoi de métadonnées, de descriptions de schémas et de résultats agrégés. Les requêtes ou transformations proposées par le modèle sont validées puis exécutées sur l'infrastructure de NovaTech.

3. Offre commerciale et support

Formule	Prix mensuel	Utilisateurs inclus	Support
Starter	390 MAD	5	Email - 48 h
Business	1 490 MAD	25	Email + chat - 8 h ouvrées
Enterprise	Sur devis	Illimité	Support prioritaire 24/7

La formule Business est la plus utilisée : elle représente 57 % des abonnements actifs en septembre 2026. Les clients Enterprise disposent d'un responsable de compte dédié. Le délai cible de première réponse pour une demande critique Enterprise est de 30 minutes.

Le support standard est fermé le dimanche. Toutefois, le support Enterprise 24/7 reste actif tous les jours, y compris les jours fériés. Les incidents sont classés de P1 à P4. Un incident P1 correspond à

une indisponibilité totale du service pour un client sans solution de contournement.

4. Projet interne Atlas

Le Projet Atlas est un programme interne lancé le 3 février 2026. Son objectif est de construire un assistant documentaire capable de rechercher des informations dans les procédures internes, les contrats, les rapports de projet et la documentation technique. Atlas utilise une architecture RAG avec segmentation des documents, embeddings, base vectorielle et modèle de langage.

Lors du premier prototype, les documents étaient divisés en chunks de 800 caractères avec un chevauchement de 120 caractères. Les tests ont montré que cette configuration était correcte pour des procédures courtes, mais moins efficace sur les documents techniques contenant de longues sections. L'équipe a ensuite testé des chunks basés sur les titres et paragraphes afin de mieux préserver le contexte.

Le responsable du projet Atlas est Omar Lahlou. L'équipe comprend deux ingénieurs ML, deux développeurs backend, une ingénieure data et une spécialiste sécurité. Le budget initial approuvé pour 2026 est de 720 000 MAD.

5. Résultats des tests RAG

Une campagne de validation a été menée sur 240 questions rédigées par des employés. Avec une récupération Top-3, le système a retrouvé au moins un passage pertinent pour 88 % des questions. En passant à Top-5, ce taux est monté à 94 %, mais le contexte envoyé au modèle est devenu plus long et plus coûteux.

L'équipe a défini trois métriques principales : le taux de récupération de passages pertinents, la fidélité de la réponse aux passages récupérés et la précision des citations. Le meilleur prototype testé en août 2026 a obtenu 94 % de rappel de récupération, 91 % de fidélité et 96 % de citations correctes.

Un problème fréquent concerne les questions ambiguës. Par exemple, la question « Quel est le délai de support ? » peut correspondre à plusieurs formules commerciales. Le système doit demander une précision ou présenter les délais par formule plutôt que d'inventer un délai unique.

6. Politique de sécurité

Les documents chargés dans Atlas sont associés à un espace de travail. Un utilisateur ne doit jamais pouvoir récupérer un chunk appartenant à un espace auquel il n'a pas accès. Les permissions sont donc vérifiées avant la recherche vectorielle et une seconde fois avant l'envoi du contexte au modèle.

Les journaux d'audit sont conservés pendant 180 jours. Les fichiers originaux sont chiffrés au repos. Les clés API des fournisseurs de modèles sont stockées dans un gestionnaire de secrets et ne doivent pas apparaître dans le code source ou les journaux applicatifs.

Tout document classé « Confidentiel - Direction » est exclu des environnements de démonstration. Les données de test doivent être fictives ou anonymisées.

7. Calendrier du projet Atlas

Étape	Date prévue	Résultat attendu
Prototype RAG	31 mars 2026	Recherche dans des PDF internes
Évaluation qualité	30 juin 2026	Jeu de 240 questions annotées
Pilote interne	15 septembre 2026	50 employés du département opérations
Version 1.0	20 novembre 2026	Déploiement pour l'ensemble du siège

8. Cas d'utilisation

Atlas est destiné à quatre usages principaux : retrouver rapidement une procédure, comparer des informations provenant de plusieurs documents, générer un résumé avec références et répondre aux questions des nouveaux employés. Le système ne doit pas prendre automatiquement de décisions juridiques ou financières à la place d'un responsable humain.

Exemple : un employé peut demander « Quelle est la règle de conservation des journaux d'audit ? ». La réponse attendue est 180 jours, accompagnée d'une référence vers la section sécurité. Une autre question possible est « Qui dirige le projet Atlas ? », dont la réponse est Omar Lahlou.

9. Informations volontairement dispersées

Afin de tester la capacité du retriever à combiner plusieurs passages, certaines informations sont volontairement dispersées. Le bureau de Tanger a ouvert en mai 2024 et se concentre uniquement sur les activités de recherche appliquée. Il compte 11 employés sur les 146 employés de l'entreprise.

La consommation moyenne de tokens du prototype Atlas a diminué de 32 % après l'introduction d'un reranker léger et d'une étape de compression du contexte. Cette optimisation a été déployée le 18 août 2026.

L'équipe a constaté que les requêtes contenant un nom de produit précis bénéficient d'un filtre par métadonnées avant la recherche vectorielle. Par exemple, une question portant sur InsightFlow ne devrait pas récupérer en priorité des chunks issus de la documentation d'un produit différent.

10. Mini FAQ pour tester le RAG

Q. Quand NovaTech a-t-elle été créée ?

Réponse de référence : En 2018.

Q. Qui est la responsable du pôle Data & AI ?

Réponse de référence : Nadia Benjelloun.

Q. Combien d'employés compte l'entreprise en septembre 2026 ?

Réponse de référence : 146.

Q. Quel est le prix de la formule Business ?

Réponse de référence : 1 490 MAD par mois.

Q. Quel est le délai cible pour un incident critique Enterprise ?

Réponse de référence : 30 minutes pour la première réponse.

Q. Quel est le budget initial du projet Atlas ?

Réponse de référence : 720 000 MAD.

Q. Quel Top-k a atteint 94 % de récupération pertinente ?

Réponse de référence : Top-5.

Q. Combien de temps les journaux d'audit sont-ils conservés ?

Réponse de référence : 180 jours.

Q. Quand la version 1.0 d'Atlas est-elle prévue ?

Réponse de référence : 20 novembre 2026.

Q. Quelle optimisation a réduit la consommation de tokens de 32 % ?

Réponse de référence : Un reranker léger et une compression du contexte.

Conseil de test : essayez aussi des formulations différentes de celles utilisées dans le document, par exemple « Qui pilote Atlas ? », « Quel abonnement coûte 1490 dirhams ? » ou « Pendant combien de mois environ garde-t-on les logs ? ». Un bon système RAG devrait retrouver les passages pertinents même lorsque la formulation n'est pas identique.